BAGIAN A

Nama: Kevin Sukias K
NIM: 2802526416

1. Slide 6–7 menunjukkan BatchNorm menormalisasi activation memakai mean dan variance mini-batch, lalu melakukan scaling dengan γ dan β. Karena statistik ini hanya diestimasi dari sedikit sample (misalnya 32), hasil normalization satu image ikut bergantung pada image lain dalam batch yang sama. Ketergantungan ini menambahkan noise ke setiap activation, mirip efek Dropout, sehingga model sulit menghafal training sample (Ioffe & Szegedy, 2015; Luo et al., 2019). Klaim Slide 8 tidak berlaku bila batch size terlalu kecil, karena estimasi statistik menjadi sangat noisy dan training tidak stabil. Klaim itu juga melemah bila batch size terlalu besar, karena noise hampir hilang. Selain itu, menaruh Dropout sebelum BN memicu variance shift antara mode training dan inference sehingga accuracy justru turun (Li et al., 2019).

2. Slide 10 menjelaskan degradation problem: menambah layer pada plain CNN justru menurunkan training accuracy. Penyebabnya adalah kesulitan optimization, bukan overfitting. Secara teori layer tambahan cukup mempelajari identity mapping, tetapi tumpukan convolution dan ReLU sulit dioptimasi SGD agar menghasilkan $H(x) = x$ secara tepat (He et al., 2016). Residual block (Slide 11) mengubah targetnya menjadi $y = F(x) + x$, sehingga network cukup mendorong $F(x) \approx 0$. Saat backpropagation, gradient-nya menjadi $\partial L/\partial x = \partial L/\partial y \cdot (\partial F/\partial x + I)$. Suku identitas I memberi jalur langsung bagi gradient ke layer awal tanpa perkalian berulang dengan weight. Inilah yang memitigasi vanishing gradient dari Sesi 02, yaitu gradient yang menyusut eksponensial karena dikalikan banyak faktor kurang dari satu.

3. Slide 16 membedakan kedua pendekatan. Dari sisi parameter, feature extraction pada ResNet-18 hanya melatih head (5.130 dari ±11,2 juta parameter), sedangkan fine-tuning layer4 + fc melatih ±8,4 juta. Dari sisi data, feature extraction aman untuk dataset sangat kecil, sementara fine-tuning butuh data lebih banyak agar tidak overfit (Slide 15, 28). Dari sisi komputasi, feature extraction tidak menghitung gradient backbone sehingga lebih hemat waktu dan memory per epoch. Dari sisi risiko, feature extraction tidak mengubah pretrained features, sedangkan fine-tuning bisa merusaknya jika learning rate terlalu besar. Kriteria praktisnya: mulai dari feature extraction (Slide 29), lalu beralih ke fine-tuning jika data cukup atau target domain jauh dari ImageNet (Yosinski et al., 2014).

4. Slide 20 menyebut data augmentation mensimulasikan data tambahan untuk meningkatkan generalization, jadi tujuannya hanya memperkaya distribusi training data. Validation dan test set harus deterministic (resize, crop, normalization) karena fungsinya mengukur performa pada distribusi nyata. Jika diaugmentasi secara acak, metric berubah setiap evaluasi, tidak bisa dibandingkan antar eksperimen, dan early stopping menjadi noisy. Contoh yang tidak layak adalah color jitter ekstrem dari Slide 21, terutama perubahan hue atau grayscale. Warna bulu adalah ciri pembeda ras: Bengal dan Egyptian Mau sama-sama bertotol, tetapi Bengal berwarna keemasan sedangkan Egyptian Mau keperakan. Label ras tidak invariant terhadap perubahan warna tersebut, sehingga model justru belajar dari sinyal yang salah (Shorten & Khoshgoftaar, 2019).

5. Slide 28 menyebut catastrophic forgetting terjadi bila fine-tuning terlalu agresif. Di awal training, head masih acak sehingga loss dan gradient-nya besar. Gradient besar ini mengalir ke backbone dan, dengan learning rate tinggi, menimpa pretrained weights sebelum head sempat belajar. Akibatnya features umum seperti edge dan texture rusak (Kirkpatrick et al., 2017). Strategi pertama adalah differential learning rate, misalnya 1e-4 untuk layer4 dan 1e-3 untuk fc, sehingga pretrained weights hanya bergeser sedikit sementara head belajar cepat. Strategi kedua adalah gradual unfreezing (Slide 16): latih head dengan backbone yang di-freeze terlebih dahulu, lalu unfreeze layer secara bertahap dari atas. Ketika backbone dibuka, gradient sudah kecil dan stabil karena head telah konvergen (Howard & Ruder, 2018).